

# dirbtinio intelekto kūrimas

pirma dalis

# KAS YRA INTELEKTAS

# kas yra intelektas

šachmatai

termostatas

mokymasis

iškalimas


apibendrinimas

sprendimų priėmimas

ateities numatymas


# sprendimų priėmimas

(klasifikacija)



# sprendimų priėmimas

(klasifikacija)



# ateities numatymas

(regresija)

Google akcijų kainų kaita



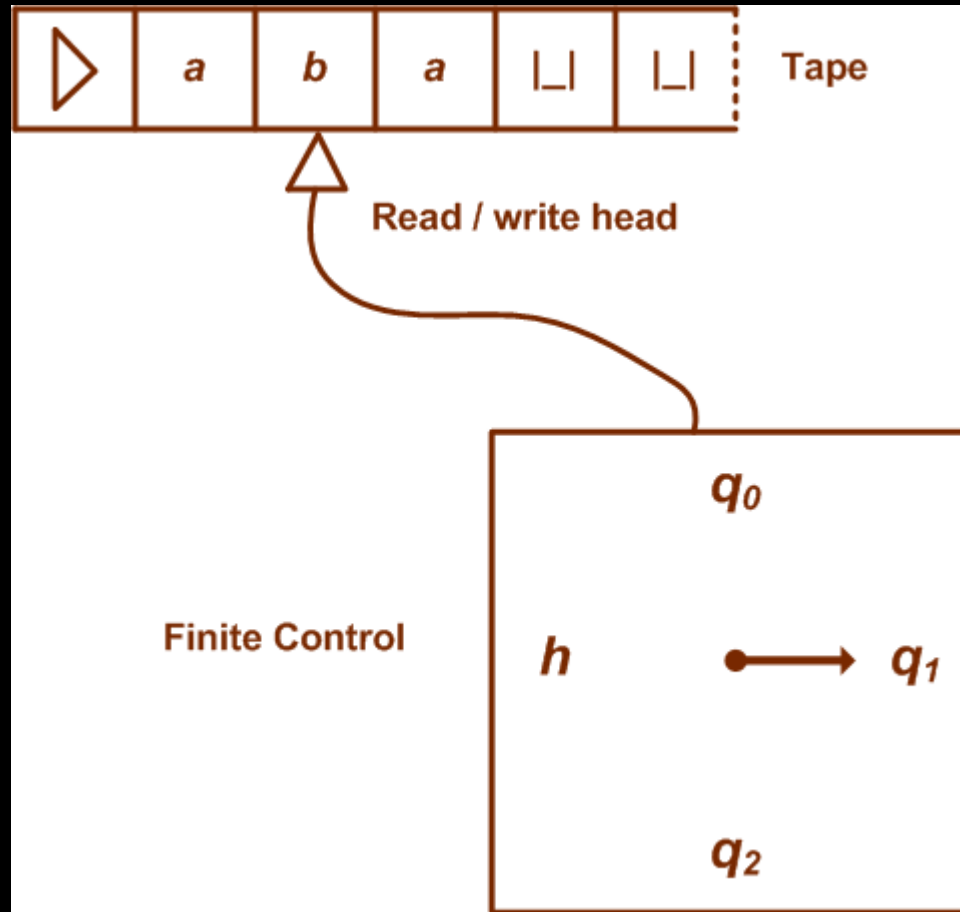
antra dalis

# NEURONINIAI TINKLAI

geras įvadas yra Christopher M. Bishop knyga „Neural Networks for Pattern Recognition“ (1995)

# turingo mašina

(~funkcija) alan turing, 1937




[wikimedia commons](#)




# universalioji turingo mašina

(~kompiuteris) alan turing, 1937



# perceptronas

frank rosenblatt, 1957



# perceptronas

$$x_1 = 170, x_2 = 10$$


$$w_1 x_1 + w_2 x_2 = -0,5 \times 170 + 0,5 \times 10 = -80$$

$$b = ?$$

$g(\text{suma} + b) =$  mergina, jei  $> 0$   
vaikinas, jei  $\leq 0$

užduotis: koks turi būti  $b$ ?

šalia taško  
nurodyta suma



# perceptronas

$$x_1 = 170, x_2 = 10$$

$$w_1 x_1 + w_2 x_2 = -0,5 \times 170 + 0,5 \times 10 = -80$$


$$b = ?$$

$g(\text{suma} + b) =$  mergina, jei  $> 0$   
vaikinas, jei  $\leq 0$

užduotis: koks turi būti  $b$ ?

atsakymas:  $-78,5 < b \leq -80$

šalia taško  
nurodyta suma



# užduotis: demokratija

aprašykite Lietuvos prezidento rinkimų  
antrojo rato principą perceptronu

konkrečiau – kas būtų

įvestis  $x_i$

svoriai  $w_i$

nuostata (bias)  $b$

aktyvumo funkcija  $g$

išvestis

# sprendimas: demokratija

aprašykite Lietuvos prezidento rinkimų  
antrojo rato principą perceptronu

konkrečiau, kas būtų

įvestis  $x_i$  = rinkėjo balsas (0 arba 1)

svoriai  $w_i = 1 / (\text{balsavusiųjų skaičius})$

nuostata (bias)  $b = 0,5$

aktyvumo funkcija  $g(z) = \begin{cases} -1, & \text{jei } z < 0; \\ 1, & \text{jei } z > 0 \end{cases}$


išvestis  $g(z) = -1$  arba  $1$

# perceptrono mokymosi taisyklė

$$\Delta \mathbf{w} = \eta (o^\mu - y^\mu) \mathbf{x}^\mu$$

arba, kai  $\eta = 1$ ,

$$\Delta \mathbf{w} = \begin{matrix} \mathbf{x}^\mu \\ -\mathbf{x}^\mu \\ 0 \end{matrix}$$




# perceptrono mokymosi taisyklė

$$\Delta \mathbf{w} = \eta (o^\mu - y^\mu) \mathbf{x}^\mu$$

arba, kai  $\eta = 1$ ,

$$\Delta \mathbf{w} = \begin{matrix} \mathbf{x}^\mu \\ -\mathbf{x}^\mu \\ 0 \end{matrix}$$






# perceptrono mokymosi taisyklė

$$\Delta \mathbf{w} = \eta (o^\mu - y^\mu) \mathbf{x}^\mu$$

arba, kai  $\eta = 1$ ,

$$\Delta \mathbf{w} = \begin{matrix} \mathbf{x}^\mu \\ -\mathbf{x}^\mu \\ 0 \end{matrix}$$




# perceptrono mokymosi taisyklė

$$\Delta \mathbf{w} = \eta (o^\mu - y^\mu) \mathbf{x}^\mu$$

arba, kai  $\eta = 1$ ,

$$\Delta \mathbf{w} = \begin{matrix} \mathbf{x}^\mu \\ -\mathbf{x}^\mu \\ 0 \end{matrix}$$




# perceptrono mokymosi taisyklė

$$\Delta \mathbf{w} = \eta (o^\mu - y^\mu) \mathbf{x}^\mu$$

arba, kai  $\eta = 1$ ,

$$\Delta \mathbf{w} = \begin{matrix} \mathbf{x}^\mu \\ -\mathbf{x}^\mu \\ 0 \end{matrix}$$




# perceptrono mokymosi taisyklė

$$\Delta \mathbf{w} = \eta (o^\mu - y^\mu) \mathbf{x}^\mu$$

arba, kai  $\eta = 1$ ,

$$\Delta \mathbf{w} = \begin{matrix} \mathbf{x}^\mu \\ -\mathbf{x}^\mu \\ 0 \end{matrix}$$




# perceptrono mokymosi taisyklė

$$\Delta \mathbf{w} = \eta (o^\mu - y^\mu) \mathbf{x}^\mu$$

arba, kai  $\eta = 1$ ,

$$\Delta \mathbf{w} = \begin{matrix} \mathbf{x}^\mu \\ -\mathbf{x}^\mu \\ 0 \end{matrix}$$




# perceptrono mokymosi taisyklė

$$\Delta \mathbf{w} = \eta (o^\mu - y^\mu) \mathbf{x}^\mu$$

arba, kai  $\eta = 1$ ,


$$\Delta \mathbf{w} = \begin{matrix} \mathbf{x}^\mu \\ -\mathbf{x}^\mu \\ 0 \end{matrix}$$



# neuroniniai tinklai

(daugiasluoksnis perceptronas)

A simple neural network




[wikimedia commons](#)

dviejų sluoksnių  
pakanka bet  
kokios tolygios  
funkcijos  
aproksimacijai

# užduotis: sprendimų režiai

A simple neural network

input layer    hidden layer    output layer



perceptrono  
sprendimų režis  
yra tiesė  
o dvisluoksnio  
neuroninio tinklo?




# sprendimas: sprendimų režiai


vienas perceptronas –  
viena tiesė

$n$  perceptronų –  $n$  tiesių

$n$  tiesių – iškilasis  
daugiakampis



# sprendimų rėžiai




gali priimti sudėtingesnius  
(netiesinius) sprendimus

# neuroninių tinklų trūkumai

A simple neural network

input layer    hidden layer    output layer




[wikimedia commons](#)

kiek reikia paslėptųjų  
neuronų?

sprendinys nebūtinai  
optimaliausias

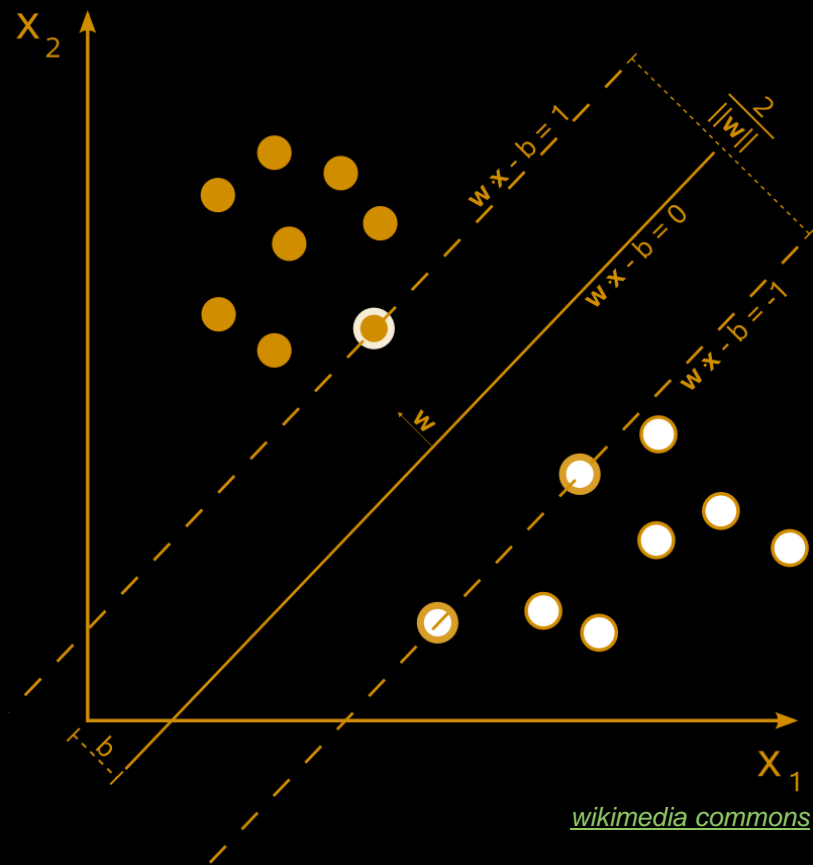
# support vector machine

vladimir vapnik, 1963



[wikimedia commons](#)

perceptronas randa  
skiriančiąsias tieses  $H_1$  ir  $H_2$



[wikimedia commons](#)


SVM randa *optimaliausia*  
skiriančiąją tiesę  $H_2$

# SVM galimybės

duoti ranka rašyti skaičiai



išmaišome seką ir pridedame daug triukšmo. kur kuris skaitmuo?




# SVM galimybės


duoti ranka rašyti skaičiai



išmaišome seką ir pridedame daug triukšmo. kur kuris skaitmuo?



SVM sprendinys




# SVM galimybės


duoti ranka rašyti skaičiai



išmaišome seką ir pridedame daug triukšmo. kur kuris skaitmuo?



SVM sprendinys



teisingas atsakymas



# evoliuciniai algoritmai

imam operatorius (+, −)

imam elementarias funkcijas (sin, cos)

kombinuojam


patikrinam, kaip gerai modelis aiškina  
rezultatus

atrenkame geriausius modelius

kombinuojame toliau



# fizikos dėsnių išvedimas



[Schmidt & Lipson, Science \(2009\)](#)

išmatuojame vertes

randame geriausią modelį

problemos:

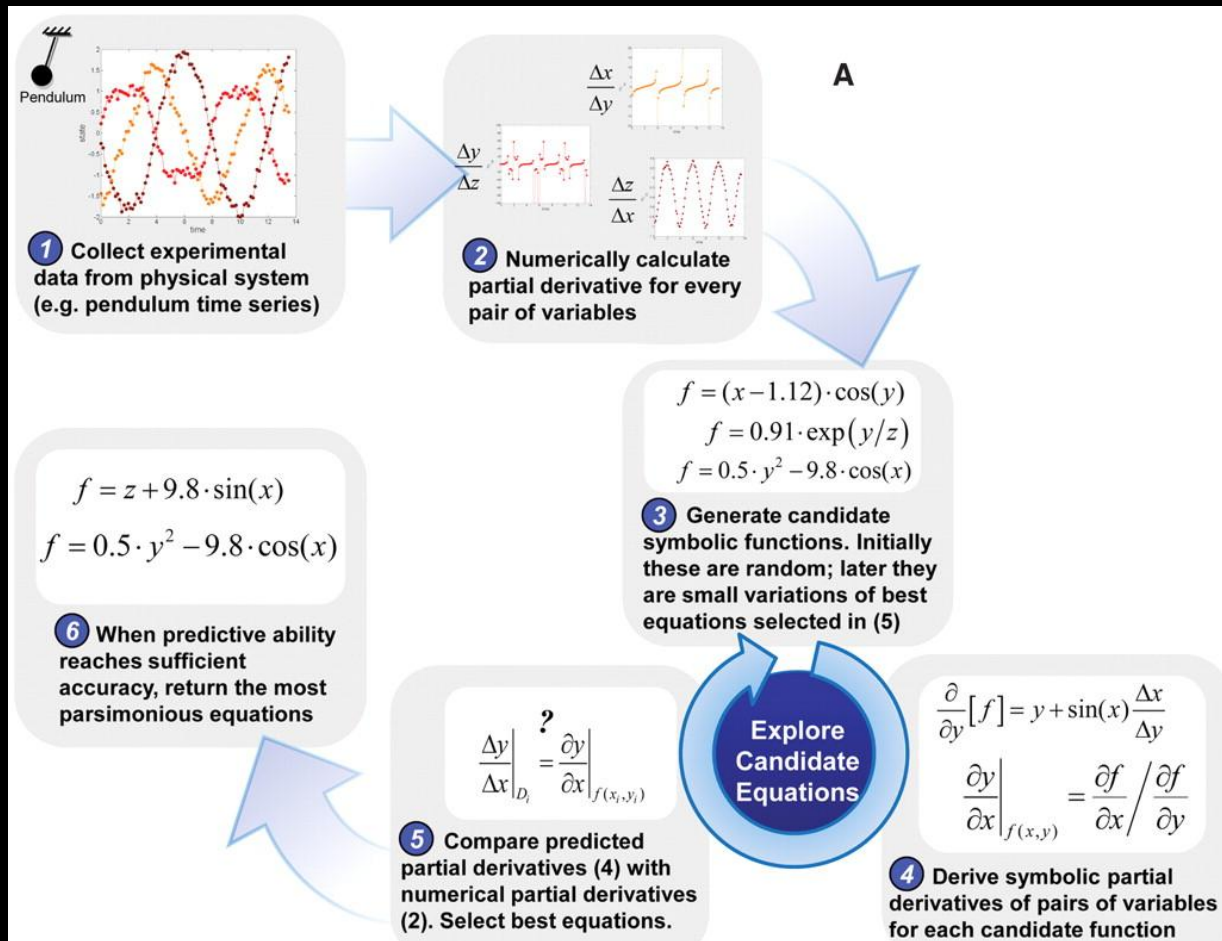
begalo daug trivialių sprendinių, pvz.,  $\sin^2x + \cos^2x$

begalo daug pakankamai gerų artinių, pvz.,  $4,56 + 1/(100 + x^2)$


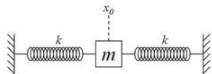
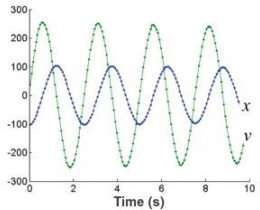

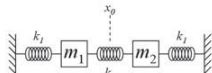
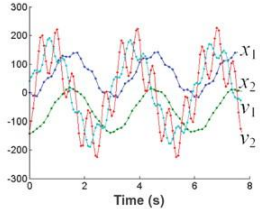

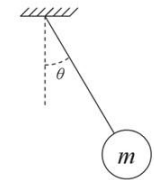
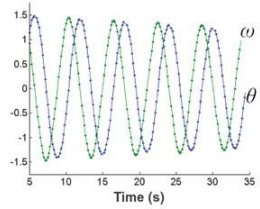

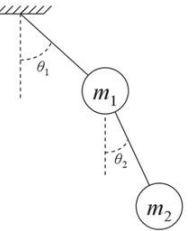
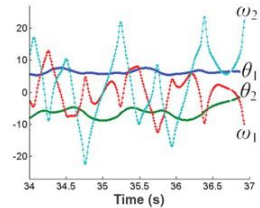
sprendimas:

gero modelio dinaminės savybės turi atitikti sistemos dinamines savybes, pvz., modeliuojant švytuoklės poziciją, turi automatiškai būti sumodeliuotas ir jos greitis

# fizikos dėsnių išvedimas



# fizikos dėsnių išvedimas

Physical System	Schematic	Experimental Data	Inferred Laws
			$114.28v^2 + 692.32x^2$ <p>Hamiltonian</p> $v^2 - 6.04x^2$ <p>Lagrangian</p> $a - 0.008v - 6.02x$ <p>Equation of motion</p>
			$-142.19x_1 - 74.65x_2 + 0.12x_1^2 - 1.89x_1x_2 - 1.51x_2^2 - 0.49v_2^2 + 0.41v_1v_2 - 0.082v_1^2$ <p>Lagrangian</p>
			$1.37 \cdot \omega^2 + 3.29 \cdot \cos(\theta)$ <p>Lagrangian</p> $2.71\alpha + 0.054\omega - 3.54\sin(\theta)$ <p>Equation of motion</p> $(x - 77.72)^2 + (y - 106.48)^2$ <p>Circular manifold</p>
			$\omega_1^2 + 0.32\omega_2^2 - 124.13\cos(\theta_1) - 46.82\cos(\theta_2) + 0.82\omega_1\omega_2\cos(\theta_1 - \theta_2)$ <p>Hamiltonian</p>

trečia dalis

# SUDĖTINGUMAS

*paruošta remiantis Gary W. Flake knyga „The Computational Beauty of Nature“ (1999)*

# kas yra sudėtinga

pietų gaminimas

tvarkingas procesas

aprašomas receptu


monetos mėtymas

atsitiktinis procesas

bet aprašomas statistiškai

# kas yra sudėtinga

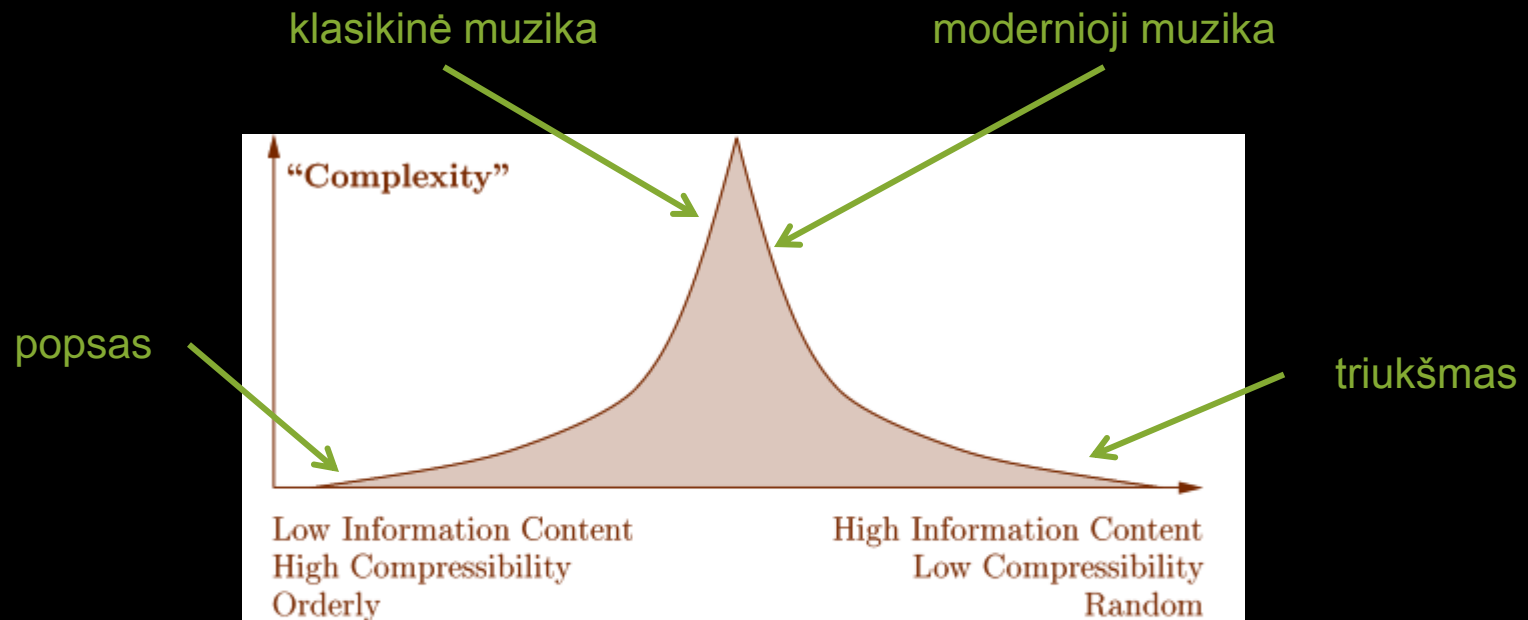
smegenys?



**Figure 9.3** Complexity in terms of information, compressibility, and randomness

Figure from *The Computational Beauty of Nature: Computer Explorations of Fractals, Chaos, Complex Systems, and Adaptation*. Copyright © 1998–2000 by Gary William Flake. All rights reserved. Permission granted for educational, scholarly, and personal use provided that this notice remains intact and unaltered. No part of this work may be reproduced for commercial purposes without prior written permission from the MIT Press.

# intarpas: menas



**Figure 9.3** Complexity in terms of information, compressibility, and randomness

Figure from *The Computational Beauty of Nature: Computer Explorations of Fractals, Chaos, Complex Systems, and Adaptation*. Copyright © 1998–2000 by Gary William Flake. All rights reserved. Permission granted for educational, scholarly, and personal use provided that this notice remains intact and unaltered. No part of this work may be reproduced for commercial purposes without prior written permission from the MIT Press.

# intarpas: meno taisyklės


organizmui būdinga ieškoti taisyklių  
aplinkoje

ypatingai talpios (gerai ir paprastai ateitį  
numatančios taisyklės) yra gražios

menas yra kuo talpesnių taisyklių radimas ir  
parodymas žiūrovui



# įvairūs procesai



**Figure 9.3** Complexity in terms of information, compressibility, and randomness

Figure from *The Computational Beauty of Nature: Computer Explorations of Fractals, Chaos, Complex Systems, and Adaptation*. Copyright © 1998–2000 by Gary William Flake. All rights reserved. Permission granted for educational, scholarly, and personal use provided that this notice remains intact and unaltered. No part of this work may be reproduced for commercial purposes without prior written permission from the MIT Press.


# fraktalai

mandelbroto aibė

$$x_{t+1} = x_t^2 + c$$


priklauso visi kompleksiniai skaičiai  $c$ , su kuriais ši seka yra apribota (bounded)

( $x_0 = 0$ )



[wikimedia commons](#)

# fraktalai



**Figure 8.3** The Mandelbrot Set: Moving from left to right and top to bottom each subsequent image shows the boxed region from the previous image in greater detail.

Figure from *The Computational Beauty of Nature: Computer Explorations of Fractals, Chaos, Complex Systems, and Adaptation*. Copyright © 1998–2000 by Gary William Flake. All rights reserved. Permission granted for educational, scholarly, and personal use provided that this notice remains intact and unaltered. No part of this work may be reproduced for commercial purposes without prior written permission from the MIT Press.





# chaosas

deterministinis procesas!


pavyzdys: logistinis atvaizdis

$$x_{t+1} = 4rx_t(1-x_t)$$

# chaos



# chaosas



**Figure 9.3** Complexity in terms of information, compressibility, and randomness


Figure from *The Computational Beauty of Nature: Computer Explorations of Fractals, Chaos, Complex Systems, and Adaptation*. Copyright © 1998–2000 by Gary William Flake. All rights reserved. Permission granted for educational, scholarly, and personal use provided that this notice remains intact and unaltered. No part of this work may be reproduced for commercial purposes without prior written permission from the MIT Press.

ketvirta dalis

# ŽMOGUS PRIEŠ MAŠINĄ

*įvadas į proto filosofiją suprantamai pateikiamas John Heil knygoje „Philosophy of Mind“ (2004)*

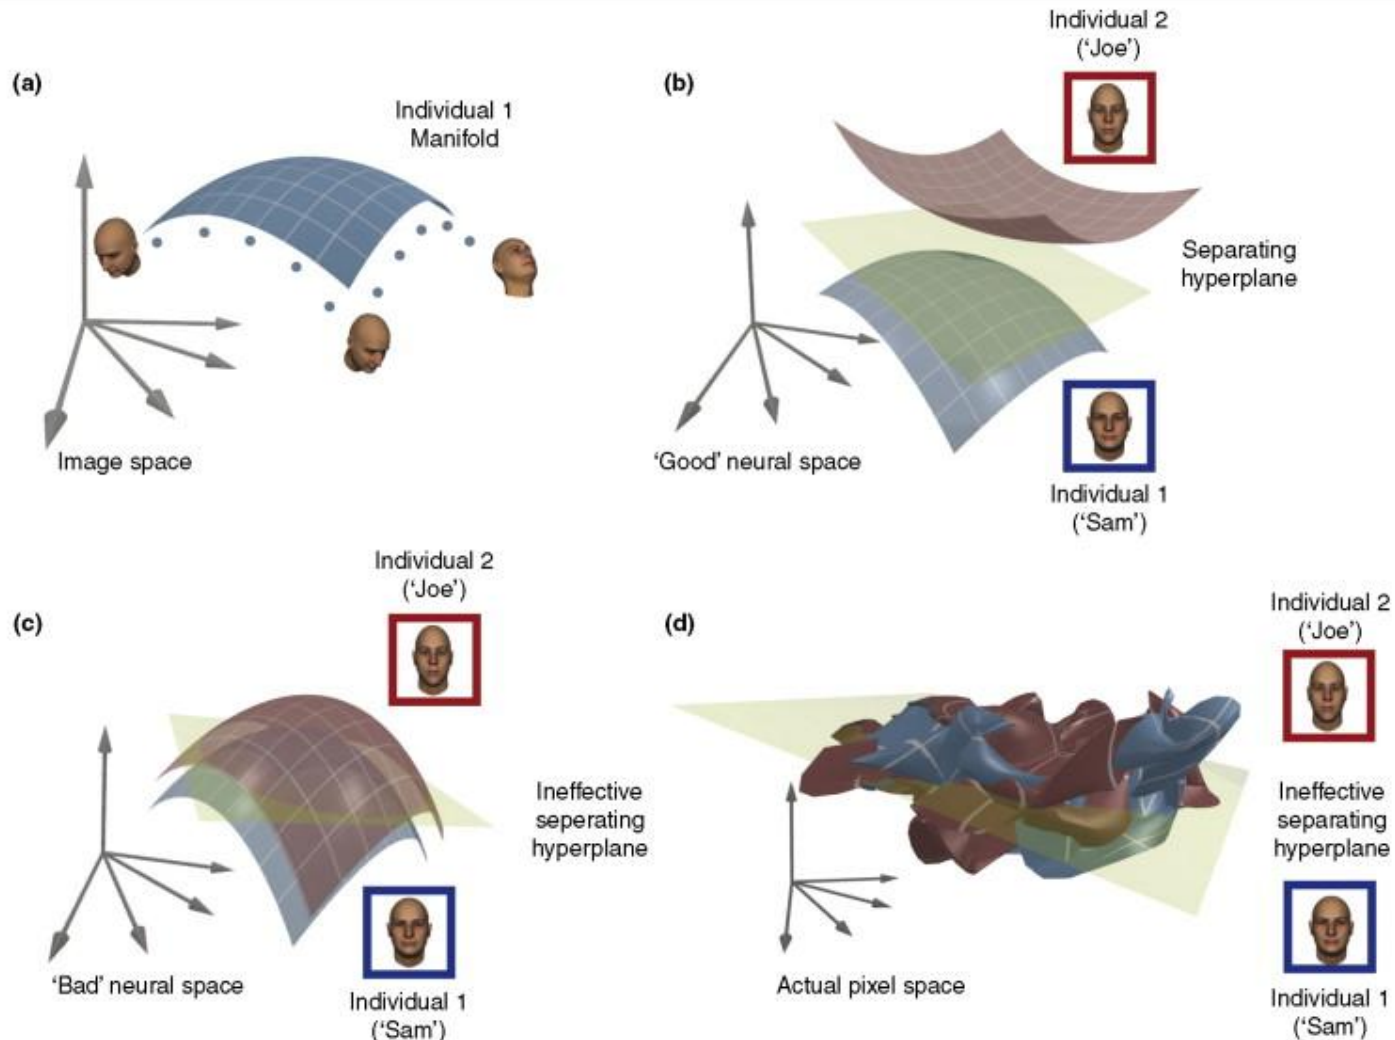
# regos sistema



TRENDS in Cognitive Sciences



# regos sistema



# proto filosofija

vyraujantis požiūris (nuo 1970-ųjų):  
funkcionalizmas

vyraujantis mokslininkų požiūris

strong AI: Tiuringo mašina yra būtina ir pakankama intelekto sąlyga

weak AI: Tiuringo mašina sėkmingai gali simuliuoti smegenų veikimą, tačiau ji niekada nebus sąmoninga

vyraujantis filosofų požiūris

Tiuringo mašina negali sėkmingai simuliuoti smegenų, nes trūksta priežastinių ryšių

# pabaigai

Since age 15 or so  
Prof. Jürgen Schmidhuber's  
main scientific ambition has been  
to build an optimal scientist,  
then retire.

– Jürgen Schmidhuber